

**INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO
TRIÂNGULO MINEIRO – *Campus* Uberaba**

**Programa de Pós-Graduação
Mestrado Profissional em Produção Vegetal**

DANIEL ABREU

**QUANTIFICAÇÃO DO POTENCIAL DE REDUÇÃO DE EMISSÕES E
CUSTOS POR MEIO DA OTIMIZAÇÃO DO TEMPO OCIOSO DE TRATORES
AGRÍCOLAS: UMA ANÁLISE BASEADA EM DADOS DE TELEMETRIA DE
ACESSO PÚBLICO.**

UBERABA – MG

2025

DANIEL ABREU

**QUANTIFICAÇÃO DO POTENCIAL DE REDUÇÃO DE EMISSÕES E
CUSTOS ATRAVÉS DA OTIMIZAÇÃO DO TEMPO OCIOSO DE TRATORES
AGRÍCOLAS: UMA ANÁLISE BASEADA EM DADOS DE TELEMETRIA DE
ACESSO PÚBLICO.**

Dissertação apresentada ao Programa de Pós-graduação em Produção Vegetal, do Instituto Federal de Educação, Ciência e Tecnologia do Triângulo Mineiro, como requisito para obtenção do Título de Mestre em Produção Vegetal.

Linha de Pesquisa: Sistemas Produtivos no Cerrado

Orientador: Prof. Dr. Daniel Pena Pereira

Coorientadora: Prof. Dra. Maytê Maria A. P. de M. Silva

Uberaba – MG

2025

[Ficha catalográfica]

DANIEL ABREU

**QUANTIFICAÇÃO DO POTENCIAL DE REDUÇÃO DE EMISSÕES E
CUSTOS POR MEIO DA OTIMIZAÇÃO DO TEMPO OCIOSO DE TRATORES
AGRÍCOLAS: UMA ANÁLISE BASEADA EM DADOS DE TELEMETRIA DE
ACESSO PÚBLICO.**

Dissertação apresentada ao Programa de
Pós-graduação em Produção Vegetal, do
Instituto Federal de Educação, Ciência e
Tecnologia do Triângulo Mineiro, como
requisito para obtenção do Título de
Mestre em Produção Vegetal.

Linha de Pesquisa: Sistemas Produtivos
no Cerrado

Uberaba, 5 março de 2026.

BANCA EXAMINADORA

Prof. Dr. Daniel Pena Pereira
(IFTM- Orientador)

Prof. Dra. Maytê Maria Abreu Pires de Melo Silva
(IFTM- Membro interno)

Dr. Étore Francisco Reynaldo
(Syngenta - Membro externo)

[Folha de Aprovação]

A Deus, pelo dom da vida e pela força nos dias em que a fé foi o único combustível disponível.

À minha esposa e ao meu filho, razão e destino de cada esforço.

Ao meu amigo Diego, que acreditou nesta jornada antes mesmo de eu enxergar o caminho.

AGRADECIMENTOS

A Deus, por cada dia concedido e pela serenidade nos momentos em que o caminho pareceu mais longo do que as forças disponíveis.

À minha esposa, Carla Gonçalves Pereira, pelo amor que sustenta, pela paciência que não se mede e pela presença em cada linha escrita. Ao meu filho, Pedro Tech Pereira Abreu, que mesmo sem saber, deu urgência e propósito a este trabalho, tudo isso é para você.

Ao meu amigo Diego Queiroz de Almeida Alegria, que esteve ao meu lado no início desta jornada, quando a ideia ainda era maior do que o plano. Seu apoio foi o alicerce sobre o qual tudo o mais se construiu.

Ao Prof. Dr. Daniel Pena Pereira, orientador que soube equilibrar rigor e liberdade, confiando nas escolhas metodológicas mesmo quando o caminho era pouco convencional. À Profa. Dra. Maytê Maria Abreu Pires de Melo Silva, coorientadora que, com paciência e generosidade, ajudou a transformar ideias dispersas em ciência organizada.

À BASF e a Syngenta, por permitir e apoiar a conclusão desta jornada, reconhecendo que o desenvolvimento profissional e a formação científica caminham juntos.

Ao IFTM - Instituto Federal de Educação, Ciência e Tecnologia do Triângulo Mineiro - Campus Uberaba, pela oportunidade de acesso a um ensino público de qualidade. Que esta dissertação retribua, ainda que em parte, o investimento que a sociedade faz em suas instituições.

RESUMO

A agricultura digital contemporânea caracteriza-se pela geração massiva de dados, impulsionada pela adoção de sistemas de telemetria baseados em barramento CAN e GNSS. No entanto, a latência entre a coleta desses dados e a geração de *insights* acionáveis permanece um gargalo crítico. Este estudo investiga a eficiência operacional de frotas mecanizadas, focando na quantificação e mitigação do tempo ocioso (*idle time*). Utilizou-se o conjunto de dados *Agricultural Load Cycles*, compreendendo 881,4 horas de operação real de cinco tratores Fendt no sul da Alemanha, totalizando um consumo monitorado de 11.310 litros de diesel com uma média global de 12,8 L/h. Através de um *pipeline* de Engenharia de Dados desenvolvido em Python, que empregou processamento paralelo e tipagem estrita para consolidação de mais de 31 milhões de registros, aplicou-se um algoritmo determinístico para classificar estados operacionais. Adotou-se o critério de velocidade inferior a 0,75 m/s (2,7 km/h) e rotação de motor sem carga para definição de ociosidade, alinhado à literatura especializada. Os resultados revelaram que 163,0 h (18,5%) do tempo total de operação foi improdutivo, resultando em um consumo excedente de 453,9 L (4,1%) de diesel e a emissão evitável de 1,2 tonelada de CO_2 na atmosfera. A análise detalhada por atividade apontou a categoria "Geral" ("*Not Working*") e operações de Transporte ("*transportation*") como as maiores contribuidoras para os custos adicionais e emissões. O estudo conclui propondo um *framework* para a transição de métodos determinísticos para modelos de Aprendizado de Máquina (*Random Forest*), visando a classificação de atividades não rotuladas para maximizar a rentabilidade e sustentabilidade da produção.

Palavras-chave: Agricultura 4.0; Efeito Estufa; Telemetria agrícola; Tempo Ocioso.

ABSTRACT

Contemporary digital agriculture is characterized by massive data generation, driven by the adoption of telemetry systems based on CAN bus and GNSS. However, the latency between data collection and the generation of actionable insights remains a critical bottleneck. This study investigates the operational efficiency of mechanized fleets, focusing on the quantification and mitigation of idle time. The *Agricultural Load Cycles* dataset was utilized, comprising 881.4 hours of real-world operation from five Fendt tractors in southern Germany, totaling a monitored consumption of 11,310 liters of diesel with a global average of 12.8 L/h. Using a Data Engineering pipeline developed in Python, which employed parallel processing and strict typing to consolidate over 31 million records, a deterministic algorithm was applied to classify operational states. An idling definition criterion of speed lower than 0.75 m/s (2.7 km/h) combined with no-load engine speed was adopted, aligning with specialized literature. The results revealed that 163.0 h (18.5%) of the total operating time was unproductive, resulting in an excess consumption of 453.9 L (4.1%) of diesel and the avoidable emission of 1.2 tonnes of CO_2e into the atmosphere. Detailed activity analysis identified the "Not working" category, along with "transportation" operations, as the major contributors to inefficiency. The study concludes by proposing a framework for transitioning from deterministic methods to Machine Learning models (*Random Forest*), aiming at the classification of unlabeled activities to maximize production profitability and sustainability.

Keywords: Agriculture 4.0; Greenhouse effect; Agriculture Telemetry; Idle Time.

LISTA DE FIGURAS

- Figura 1 - Dispersão do consumo horário de combustível (L/h) por modelo de trator da frota avaliada.. 28
- Figura 2 - Variabilidade do consumo de combustível (L/h) por atividade agrícola da frota avaliada..... 30
- Figura 3 - Balanço operacional global: distribuição percentual do tempo de atividade (esquerda) e a respectiva participação no consumo total de combustível (direita)..... 32
- Figura 4 - Eficiência energética da frota: diagrama hierárquico (*Sunburst*) relacionando o consumo absoluto (tamanho) e o índice de ineficiência (cor) por trator e atividade.... 34

LISTA DE TABELAS

Tabela 1. Estatística descritiva do consumo de combustível (L/h) por trator. Motor ativo (RPM $\geq$ 100)	28
Tabela 2 — Estatística descritiva do consumo de combustível (L/h) por atividade agrícola. Motor ativo (RPM $\geq$ 100); outliers removidos pelo critério $IQR \times 1,5$	28
Tabela 3 — Comparação múltipla de médias de consumo de combustível (L/h) por trator, em delineamento inteiramente casualizado com blocos de 8 horas; teste de Tukey HSD; $\alpha = 0,001$; n = 55 blocos por tratamento.....	31
Tabela 4 — Consumo médio de combustível (L/h) por atividade agrícola e agrupamento estatístico em DIC com blocos de 8 horas; teste de Tukey HSD; $\alpha = 0,001$; n = 14 blocos por tratamento.....	32
Tabela 5 — Consumo de combustível e indicadores de desperdício por unidade da frota monitorada	37

LISTA DE ABREVIATURAS E SIGLAS

ACV - Avaliação do Ciclo de Vida

ALC - *Agricultural Load Cycles* (conjunto de dados de ciclos de carga agrícola)

ANOVA - *Analysis of Variance* (Análise de Variância)

CAN - *Controller Area Network* (rede de barramento de comunicação veicular)

CBIOs - Créditos de Descarbonização por Biocombustíveis

CLD - *Compact Letter Display* (representação de agrupamentos estatísticos)

CO_{2e} - Dióxido de Carbono equivalente

CPU - *Central Processing Unit* (Unidade Central de Processamento)

DIC - Delineamento Inteiramente Casualizado

ECU - *Electronic Control Unit* (Unidade de Controle Eletrônico)

EPA - *Environmental Protection Agency* (Agência de Proteção Ambiental dos EUA)

ESG - *Environmental, Social and Governance* (Ambiental, Social e Governança)

FAO - *Food and Agriculture Organization of the United Nations* (Organização das Nações Unidas para a Alimentação e a Agricultura)

GEE - Gases de Efeito Estufa

GNSS - *Global Navigation Satellite System* (Sistema Global de Navegação por Satélite)

HSD - *Honestly Significant Difference* (teste de Tukey)

Hz - Hertz (unidade de frequência)

IFTM - Instituto Federal de Educação, Ciência e Tecnologia do Triângulo Mineiro

IoT - *Internet of Things* (Internet das Coisas)

IPCC - *Intergovernmental Panel on Climate Change* (Painel Intergovernamental sobre Mudanças Climáticas)

ISOBUS - Norma ISO 11783 (padrão de comunicação trator–implemento)

J1939 - Norma SAE J1939 (protocolo de comunicação CAN para veículos pesados)

L/h - Litros por hora

LTE - *Long Term Evolution* (tecnologia de comunicação móvel 4G)

NO_x - Óxidos de Nitrogênio

RPM - Rotações por Minuto

SAE - *Society of Automotive Engineers* (Sociedade de Engenheiros Automotivos)

TDP - Tomada de Potência

TUM - *Technische Universität München* (Universidade Técnica de Munique)

VT - *Virtual Terminal* (Terminal Virtual)

SUMÁRIO

1. INTRODUÇÃO.....	15
2. REVISÃO DE LITERATURA.....	17
2.1. AGRICULTURA 4.0 E A ERA DO BIG DATA	17
2.2. IMPACTO AMBIENTAL E EMISSÕES DE CO_2e	18
2.3. TELEMETRIA E CONECTIVIDADE EM MÁQUINAS AGRÍCOLAS.....	19
2.4. TEMPO OCIOSO (<i>IDLE TIME</i>) EM OPERAÇÕES MECANIZADAS.....	20
3. MATERIAL E MÉTODOS.....	22
3.1. AQUISIÇÃO E CARACTERIZAÇÃO DO DATASET.....	22
3.2. PROCESSAMENTO DE DADOS E PIPELINE PYTHON.....	24
3.3. DEFINIÇÃO E MODELAGEM DO ESTADO DE OCIOSIDADE.....	25
4. RESULTADOS E DISCUSSÃO.....	27
4.1. CARACTERIZAÇÃO DA AMOSTRA E ANÁLISE ESTATÍSTICA DO CONSUMO.....	27
4.2. ANÁLISE GLOBAL DA FROTA E EFICIENCIA OPERACIONAL..	31
4.3. CENÁRIOS DE MITIGAÇÃO E IMPACTO AMBIENTAL.....	36
4.4. OPORTUNIDADE DE APERFEIÇOAMENTO METODOLÓGICO..	38
5. CONCLUSÃO.....	40
REFERÊNCIAS.....	41
APÊNDICES.....	44
APÊNDICE A - PRODUTO TÉCNICO TECNOLÓGICO.....	44

1. INTRODUÇÃO

A modernização da agricultura global enfrenta o desafio dual de aumentar a produtividade para alimentar uma população crescente, enquanto mitiga os impactos ambientais e controla os custos operacionais em um cenário de margens estreitas. Neste contexto, o maquinário agrícola representa uma das maiores classes de ativos e custos variáveis dentro da porteira (Edwards et al., 2015), e a tendência global de consolidação em operações de grande escala torna a otimização da frota um fator crítico de produtividade (Key, 2019). O consumo de combustível, especificamente o diesel, não detém apenas o aspecto financeiro, mas um indicador direto da pegada de carbono da produção agrícola (Silveira et al., 2023).

A emergência da Agricultura 4.0 trouxe a conectividade para o campo. Tratores modernos são equipados com redes de sensores complexas (ISOBUS, SAE J1939) capazes de transmitir dezenas de parâmetros por segundo (CSS Electronics, 2025). Uma das ineficiências mais perniciosas e menos diagnosticadas na gestão de frotas é o tempo ocioso. Define-se *idle time* como os períodos em que o motor da máquina está ativo (consumindo combustível e depreciando o ativo via horímetro), mas a máquina não está realizando trabalho efetivo, ou seja, está parada ou em deslocamento não produtivo com velocidade irrelevante (Molari et al., 2019). As causas da ociosidade são multifatoriais, variando desde a necessidade técnica (e.g., aquecimento do motor em baixas temperaturas) (Perozzi et al., 2016), até o comportamento do operador (uso do ar-condicionado durante pausas, falta de desligamento em paradas longas) (Molari et al., 2019). Estudos indicam que grande parte desse tempo, podendo chegar até 45% do total de ociosidade, é desnecessária e evitável (Perozzi et al., 2016), representando uma oportunidade imediata de otimização.

Análises recentes sobre ciclos de carga agrícola, como as realizadas sobre o conjunto de dados *Agricultural Load Cycles* (ALC) (Götz et al., 2025), identificam o status “Geral” (*Not Working*) como um misto de paradas técnicas inevitáveis (ajustes/acoplamento) e ineficiência operacional (espera com motor ligado). Identifica-se que a maior parte desse tempo carece de justificativa técnica, apontando para um paradoxo: o setor agrícola possui mais dados do que nunca, mas a capacidade de transformar esses dados massivos em decisões de gestão de frota em tempo real ainda é limitada.

A presente pesquisa investiga a hipótese de que frotas agrícolas mecanizadas acumulam um tempo ocioso (*idle time*) significativo no tempo total de operação, que permanece oculto em análises gerenciais convencionais devido à dificuldade de processamento de dados massivos. O objetivo deste trabalho é desenvolver e validar um *pipeline* computacional determinístico capaz de processar dados de telemetria (*Big Data*) para quantificar com precisão esse estado físico de inatividade (máquina parada com motor ligado), fornecendo uma métrica objetiva para mensurar o volume de combustível desperdiçado e as emissões de CO_2e associadas, estabelecendo assim a base quantitativa necessária para futuras otimizações logísticas.

2. REVISÃO DE LITERATURA

2.1. Agricultura 4.0 e a era do *Big Data*

A agricultura contemporânea atravessa uma mudança de paradigma sem precedentes, frequentemente denominada "Quarta Revolução Agrícola" ou Agricultura 4.0. Diferente das revoluções anteriores, caracterizadas pela mecanização (2.0) e pela automação guiada por GNSS e aplicação em taxa variável (3.0/Agricultura de Precisão), a era atual é definida pela interconectividade digital ubíqua e pelo uso intensivo de dados (*Big Data*) para a tomada de decisão em tempo real (Wolfert et al., 2017). Enquanto a Agricultura de Precisão focava na gestão da variabilidade espacial (tratando cada metro quadrado de forma diferente), a Agricultura 4.0 adiciona a dimensão temporal e preditiva, permitindo que sistemas autônomos reajam a mudanças dinâmicas no ambiente produtivo.

Neste contexto, Wolfert et al. (2017) argumentam que o dado agrícola deixa de ser um subproduto operacional para se tornar um insumo produtivo tão crítico quanto fertilizantes ou sementes. Os autores destacam que a aplicação de *Big Data* na agricultura deve ser compreendida através dos "5 Vs": Volume (terabytes de telemetria gerados por frotas conectadas), Velocidade (necessidade de processamento em tempo real ou *stream processing*), Variedade (fusão de dados heterogêneos vindos de sensores de solo, imagens de satélite, estações meteorológicas e mercado de *commodities*), Veracidade (o desafio da qualidade e limpeza dos dados brutos ruidosos) e Valor (a conversão final de bytes em lucro agrônomo). A transição para a *Smart Farming* (Agricultura Inteligente) reside justamente na capacidade de integrar essas variáveis para gerenciar sistemas complexos de forma preditiva e não apenas reativa.

Entretanto, a digitalização traz desafios que transcendem a barreira tecnológica e entram na esfera sociotécnica. Klerkx et al. (2019), ao analisarem a transformação digital sob a ótica das ciências sociais, alertam para a "assimetria de poder" gerada pela propriedade dos dados. Frequentemente, os dados gerados pelas máquinas permanecem em "silos" proprietários dos grandes fabricantes de maquinário, limitando a capacidade do produtor de realizar análises independentes ou de integrar frotas mistas (multimarcas). Essa fragmentação obriga o produtor a utilizar múltiplas plataformas desconexas, dificultando a visão holística da propriedade.

Além disso, Klerkx et al. (2019) enfatizam a necessidade urgente de novas competências gerenciais, o chamado "letramento digital" (*data literacy*). Sem a capacidade de interpretar estatísticas e dashboards, o excesso de informação pode levar à paralisia decisória em vez de eficiência operacional. O gestor agrícola moderno precisa atuar como um analista de dados, discernindo entre correlação e causalidade nos relatórios gerados por algoritmos de Inteligência Artificial.

Portanto, o gargalo atual não reside mais na aquisição de dados — visto que sensores modernos já coletam milhares de pontos por minuto —, mas na "latência da informação". A capacidade de reduzir o tempo entre a coleta do dado no campo (a "borda" ou Edge Computing) e a tomada de decisão gerencial é o que define a competitividade na Agricultura 4.0. Sistemas que dependem exclusivamente de processamento em nuvem (Cloud) podem sofrer com a falta de conectividade no campo, exigindo arquiteturas híbridas onde parte do processamento ocorre na própria máquina.

2.2. Impacto ambiental e emissões de CO_2e

A discussão sobre eficiência operacional é indissociável da pauta de sustentabilidade global e mudanças climáticas. A mecanização agrícola, dependente quase exclusivamente de combustíveis fósseis (diesel), é um dos principais *hotspots* de emissão de Gases de Efeito Estufa (GEE) "dentro da porteira". Lovarelli e Bacenetti (2019), utilizando a metodologia de Avaliação do Ciclo de Vida (ACV), demonstram que, em culturas extensivas altamente mecanizadas, o consumo de diesel pode responder por mais de 50% das emissões da propriedade, superando muitas vezes as emissões associadas à fabricação dos insumos.

Silveira et al. (2023) realizaram uma revisão abrangente das tecnologias de controle de poluentes em máquinas agrícolas, detalhando a rigorosa evolução das normas de emissões, dos motores Tier 3 para os atuais Tier 4 Final e Stage V. Os autores explicam que a indústria adotou tecnologias complexas como o SCR (*Selective Catalytic Reduction*), que utiliza injeção de ureia (Arla 32) para converter Óxidos de Nitrogênio (NO_x) em nitrogênio e água, e o EGR (*Exhaust Gas Recirculation*), para reduzir a

temperatura de combustão. Esses sistemas são extremamente eficazes para neutralizar poluentes tóxicos à saúde humana, como o NO_x e o Material Particulado (MP).

As normas de emissão para máquinas agrícolas evoluíram em duas famílias regulatórias paralelas. No sistema norte-americano da Agência de Proteção Ambiental (EPA), o Tier 3 (vigente de 2006 a 2008 para motores de 37 a 560 kW) impunha limites combinados de NO_x+HC que podiam ser atendidos majoritariamente por avanços no projeto interno do motor, sem sistemas de pós-tratamento obrigatórios. A transição para o Tier 4 Final, concluída em 2015, representou uma ruptura tecnológica ao exigir redução de 90% nas emissões de NO_x e Material Particulado (MP) em relação ao Tier 3, tornando indispensável o uso conjugado de SCR, DPF e EGR (U.S. EPA, 2004). No contexto europeu, o Stage V, estabelecido pelo Regulamento (UE) 2016/1628 e em vigor desde janeiro de 2019, representa o padrão mais restritivo do mundo para motores não rodoviários. Além de limites de NO_x alinhados ao Tier 4 Final, o Stage V introduziu pela primeira vez um limite de Número de Partículas (PN) de 1×10^{12} partículas $\cdot kWh^{-1}$ para motores de 19 a 560 kW, tornando o uso de filtros DPF universal nessa categoria (Parlamento Europeu, 2016). Os tratores da frota analisada neste estudo, todos da marca Fendt e operados na Alemanha, enquadram-se nessa última categoria. No Brasil, a regulamentação equivalente é o PROCONVE/MAR (Programa de Controle de Emissões de Máquinas Agrícolas e Rodoviárias), instituído pela Resolução CONAMA nº 433/2011, cuja fase MAR-I — com limites próximos ao Tier 3/Stage IIIA — está em processo de consolidação para diversas faixas de potência, enquanto a fase MAR-II, com limites equivalentes ao Tier 4 Final, ainda se encontrava em fase de proposta regulatória perante o CONAMA até 2025 (IBAMA, 2025), evidenciando uma defasagem temporal relevante em relação às normas europeia e americana.

No entanto, Silveira et al. (2023) fazem uma distinção crucial que muitas vezes passa despercebida: não existe filtro para CO_2 . O Dióxido de Carbono (CO_2) é um produto estequiométrico inevitável da combustão completa de hidrocarbonetos. A reação química básica da queima do diesel libera cerca de 2,6 kg de CO_2 para cada litro consumido. Portanto, enquanto o NO_x e a fumaça preta podem ser resolvidos com catalisadores químicos e filtros DPF, a única forma física de reduzir a emissão de CO_2 é queimar menos combustível.

Neste cenário, a redução do tempo ocioso se posiciona como uma estratégia ambiental superior até mesmo à renovação da frota. Mesmo um trator de última geração (Stage V),

equipado com os filtros mais modernos, se deixado ocioso desnecessariamente, continua emitindo CO_2 na atmosfera sem produzir alimento, com eficiência térmica nula. A FAO (2023) reforça que a eficiência energética e a digitalização são pilares centrais para a descarbonização dos sistemas agroalimentares globais. Para o produtor brasileiro, a comprovação auditável dessa redução de emissões via telemetria pode abrir portas para o mercado de Créditos de Descarbonização (CBIOS) no âmbito da Política Nacional de Biocombustíveis (RenovaBio) e programas de certificação de *commodities* sustentáveis conforme estabelecido pela Lei nº 13.576 (BRASIL, 2017), transformando a eficiência de dados em ativo financeiro ambiental.

2.3. Telemetria e conectividade em máquinas agrícolas

Paraforos e Griepentrog (2019) detalham que, em um trator moderno, dezenas de Unidades de Controle Eletrônico (ECUs) trocam mensagens continuamente sobre o estado da máquina. Parâmetros como rotação do motor (RPM), torque, consumo instantâneo de combustível, temperatura de fluidos, pressão hidráulica e patinagem dos rodados são transmitidos em frequências que podem superar 100 Hz. A padronização dessa troca de dados entre o trator e os implementos (como plantadeiras, distribuidores de adubo e pulverizadores) é regida pela norma ISO 11783, comercialmente conhecida como ISOBUS. O objetivo do ISOBUS é o conceito de *Plug-and-Play*: permitir que um trator de uma marca controle um implemento de outra marca através de um Terminal Virtual (VT) único na cabine, simplificando a operação para o usuário (Bochtis et al., 2014).

Contudo, a realidade de campo é mais complexa. Ressalta-se que a simples existência do padrão ISOBUS não resolve todos os problemas de gestão de frota. A heterogeneidade na implementação dos padrões pelos fabricantes (os chamados "dialetos" proprietários das mensagens CAN) muitas vezes obriga os pesquisadores e gestores a desenvolverem *pipelines* de limpeza e harmonização de dados complexos, um processo conhecido como *Canonical Data Mapping*. Sem essa etapa de engenharia de dados, a análise comparativa entre um trator da marca A e da marca B torna-se inviável, pois os identificadores de parâmetros podem divergir ou estar ocultos em canais proprietários, obscurecendo ineficiências sistêmicas da operação.

A evolução recente para sistemas de *Cloud Computing* e *Internet das Coisas* (IoT) permite que esses pacotes de dados CAN, anteriormente restritos ao cartão de memória da máquina, sejam transmitidos via redes celulares (4G/LTE/5G) ou satelitais para servidores remotos em tempo quase real. Essa conectividade permite o monitoramento de "missões" operacionais completas, onde o desempenho da máquina pode ser auditado em função da topografia, do tipo de solo e da habilidade do operador. Paraforos e Griepentrog (2019) apontam que essa integração permite a criação de "Gêmeos Digitais" (*Digital Twins*) da frota, onde simulações computacionais podem prever o desgaste de componentes ou o consumo de combustível antes mesmo de a máquina entrar no talhão.

2.4. Tempo Ocioso (*Idle Time*) em operações mecanizadas.

Na busca por eficiência energética e redução de custos operacionais, o tempo ocioso (*idle time*) emergiu na literatura recente como um dos principais "ladrões silenciosos" de rentabilidade. Molari et al., (2019), em estudo sobre o tema, definem ociosidade como os períodos em que o motor da máquina permanece ativo (*key-on, engine-on*), consumindo combustível e acumulando horas de manutenção, mas a unidade não está realizando trabalho agrônômico efetivo (velocidade zero ou irrelevante) nem acionando a Tomada de Potência (TDP) ou sistema hidráulico para fins produtivos.

As estatísticas levantadas por Perozzi et al. (2016) e corroboradas por Molari et al., (2019) em frotas europeias são alarmantes: tratores agrícolas passam entre 10% a 43% de seu tempo total de vida útil em estado de ociosidade. Essa variação depende intensamente do tipo de operação (preparo de solo, plantio ou transporte) e da logística da propriedade. Molari et al., (2019) aprofundaram essa análise utilizando câmeras (*dashcams*) sincronizadas com *dataloggers* CAN Bus para categorizar as causas dessas paradas. Eles descobriram que, em 67% dos eventos de ociosidade registrados, não havia justificativa técnica para o motor estar ligado (como a necessidade de manter pressão hidráulica, arrefecimento do turbo ou ar-condicionado em dias extremos). A maior parte consistia em "ociosidade evitável": pausas para conversa, espera logística por insumos (sementes/adubo), aguardo de transbordo ou simples hábito cultural do operador de não desligar a máquina.

Para combater esse desperdício, Mattetti et al. (2022) propuseram metodologias para determinar o "limite de desligamento" (*break-even point*), calculando quantos segundos

um motor deve permanecer desligado para que a economia de combustível compense o desgaste do motor de partida e da bateria na religação. Em motores modernos com injeção eletrônica, esse tempo é surpreendentemente curto: em muitos casos, paradas superiores a 15 ou 20 segundos já justificariam o desligamento do motor.

Essa ineficiência possui um efeito cascata negativo sobre o custo total de propriedade. Além do combustível queimado diretamente (que pode chegar a 3-4 litros/hora em tratores de alta potência apenas para manter o motor girando em marcha lenta), o tempo ocioso distorce os planos de manutenção preventiva. Como as revisões são baseadas em horímetro (horas-motor), uma máquina com alta ociosidade realizará trocas de óleo e filtros prematuramente em relação ao trabalho real executado. Molari et al., 2019 adicionam ainda que a operação prolongada em baixa carga e baixa temperatura pode causar danos mecânicos, reduzindo a vida útil do motor e depreciando o valor de revenda do ativo, além de serem prejudiciais ao ambiente e saúde pública.

Essa estrutura de custos é formalmente quantificada por Lattz e Schnitkey (2025), que estimam os custos operacionais de tratores por faixa de potência utilizando a abordagem de engenharia econômica (*economic engineering approach*) baseada nas formulações da ASABE. Os autores demonstram que, para um trator de 175 cv operando 300 horas por ano, os custos fixos — depreciação, juros, seguro, abrigo e reparos — podem alcançar valores superiores a US\$ 100 por hora. Crucialmente, esses custos fixos são computados por hora de horímetro, independentemente de a máquina estar realizando trabalho útil ou permanecendo ociosa. Assim, cada hora de tempo ocioso onera o custo total de propriedade na mesma proporção que uma hora produtiva, sem o retorno agrônômico correspondente. Essa constatação reforça que a redução do tempo ocioso não representa apenas uma economia direta de combustível, mas uma otimização estrutural do custo por hectare trabalhado.

3. MATERIAL E MÉTODOS

3.1. Aquisição e caracterização do *dataset*

Este estudo fundamentou-se no conjunto de dados público denominado ALC, disponibilizado por pesquisadores da Universidade Técnica de Munique (TUM) (Götz et al., 2025). A seleção deste material deve-se à sua alta precisão, caracterizada por uma frequência de amostragem de 10 Hz, ou seja, os sensores registraram a situação da máquina dez vezes a cada segundo. Essa granularidade garante uma fidelidade superior às condições reais de campo, diferindo significativamente de dados estáticos obtidos em bancadas de teste. O banco de dados compreende o registro de mais de 31 milhões de pontos de leitura, coletados de uma frota de cinco tratores da série Fendt Vario (modelos 211, 314, 722, 724 e 820), cobrindo desde tratores utilitários leves até unidades de médio-grande porte em um ciclo completo de operações agrícolas (preparo, semeadura, manejo, colheita e transporte).

Para a análise computacional, foram selecionadas as variáveis primárias extraídas da rede eletrônica dos tratores (barramento CAN) e do sistema de posicionamento global (GNSS). No arquivo digital processado, estas grandezas físicas são identificadas pelos seguintes códigos *engine_rpm* para a Rotação do Motor (rpm); *fuel_rate* para a taxa instantânea de consumo de combustível (L/h); *veh_speed* para a velocidade de deslocamento (padronizada em m/s); e timestamp para a marca temporal de alta precisão, que permite ordenar cronologicamente cada evento.

A natureza dos dados de telemetria impõe um desafio estatístico relevante: registros consecutivos amostrados a 10 Hz são altamente autocorrelacionados, uma vez que o estado físico da máquina varia de forma contínua e suave entre leituras adjacentes. A utilização direta dos milhões de registros individuais como observações independentes em testes paramétricos violaria o pressuposto de independência amostral, resultando em inflação artificial do tamanho amostral efetivo e, consequentemente, em p-valores artificialmente baixos que detectariam diferenças estatísticas sem relevância prática (Hurlbert, 1984).

Para contornar essa limitação, adotou-se uma estratégia de agregação temporal em blocos representativos. Cada bloco compreende registros consecutivos de operação contínua a 10 Hz, dentro do qual se calculou a média aritmética do consumo horário de

combustível (L/h). A agregação temporal tem dupla finalidade. Primeiro, ao representar períodos operacionais completos, os blocos constituem unidades experimentais cuja independência é sustentada pela descontinuidade natural entre turnos de trabalho, cada turno envolve condições de campo, operadores e atividades distintas, rompendo a estrutura de autocorrelação presente nos registros intra-jornada. Segundo, o elevado número de registros por bloco assegura, pelo Teorema Central do Limite, que a média amostral de cada bloco converge para a distribuição normal, viabilizando a aplicação de testes paramétricos como a ANOVA.

Os dados foram estruturados como um estudo observacional em Delineamento Inteiramente Casualizado (DIC) com dois experimentos:

Experimento 1 - Consumo por modelo de trator. Os cinco modelos de tratores constituíram os tratamentos. Após a agregação em blocos de 8 horas (288.000 registros), o número de repetições variou entre 5 (Fendt 211) e 38 (Fendt 722). Para garantir um delineamento balanceado, procedeu-se à subamostragem aleatória ($seed = 42$) de todos os tratamentos para o tamanho do menor grupo, resultando em 5 repetições por tratamento ($n \text{ total} = 25$).

Experimento 2 - Consumo por atividade agrícola. As atividades registradas na estrutura de arquivos do dataset constituíram os tratamentos. Neste experimento, adotou-se um bloco de 4 horas (144.000 registros), uma vez que diversas atividades não acumulam uma jornada completa de 8 horas ao longo da safra; o bloco de 4 horas preserva o efeito estabilizador do TCL ($n = 144.000$ registros por média) ao mesmo tempo em que amplia o número de tratamentos incluídos na análise. Foram excluídas atividades com menos de 5 blocos completos, por não apresentarem representatividade amostral suficiente, resultando em 7 atividades retidas. O balanceamento foi conduzido de forma análoga ao Experimento 1, resultando em 5 repetições por atividade ($n \text{ total} = 35$, limitado pela atividade Preparação de Canteiro).

Previamente à aplicação da ANOVA, verificaram-se os pressupostos de normalidade (teste de Shapiro-Wilk) e homocedasticidade (teste de Levene, centrado na mediana), ambos ao nível $\alpha = 0,001$. Em ambos os experimentos, todos os grupos atenderam ao pressuposto de normalidade, e a hipótese de igualdade de variâncias não foi rejeitada (Tratores: Levene $W = 0,86$; $p = 0,503$ | Atividades: Levene $W = 2,09$; $p = 0,087$). As médias foram então submetidas à Análise de Variância e, quando constatada significância, aplicou-se o teste de comparação múltipla de Tukey HSD (*Honestly Significant*

Difference), com nível de significância $\alpha = 0,001$, para estratificação dos tratamentos em grupos homogêneos. Os resultados são apresentados por meio do *Compact Letter Display* (CLD), no qual tratamentos que compartilham ao menos uma letra não diferem estatisticamente entre si. Todo o processamento estatístico foi realizado em Python 3.12, com as bibliotecas SciPy (Virtanen et al., 2020) e Statsmodels (Seabold; Perktold, 2010).

3.2. Processamento de dados e pipeline python

O desenvolvimento dos algoritmos utilizou o ambiente de programação VS Code e a linguagem Python na versão 3.12 (Python Software Foundation, 2023). A biblioteca *Pandas* (McKinney, 2010) foi empregada como a principal ferramenta para a organização e manipulação das tabelas de dados.

Dada a natureza volumosa e fragmentada do conjunto original, composto por 148 arquivos distintos, a abordagem manual via planilhas convencionais mostrou-se inviável. O principal desafio metodológico enfrentado foi a inconsistência na nomenclatura das variáveis entre os diferentes arquivos, onde uma mesma grandeza física apresentava identificadores distintos (por exemplo, a rotação do motor aparecia ora como *EngSpeed*, ora como *EngSpeed_(RPM)*). Para solucionar este problema sem intervenção manual, implementou-se um 'Dicionário de Padronização' (*Canonical Dict*). Esta estrutura funciona como uma ferramenta de tradução automática, mapeando as variações de nomes para um padrão único, garantindo que o algoritmo interpretasse corretamente os dados independentemente do modelo do trator ou da versão do *firmware*.

Adicionalmente, para mitigar a lentidão inerente à leitura de milhões de registros (gargalo de *Input/Output*), implementou-se uma rotina de processamento paralelo (biblioteca *concurrent.futures*). Esta técnica permitiu que o computador realizasse a leitura simultânea de múltiplos arquivos, em vez de processá-los um a um sequencialmente, reduzindo o tempo total de pré-processamento em aproximadamente 85%.

Na etapa seguinte, aplicou-se uma rotina de limpeza e organização dos dados. Este processo teve três objetivos práticos: 1) padronizar todas as datas e horários (*timestamps*) para um formato único cronológico; 2) assegurar que os dados dos sensores fossem armazenados com precisão decimal (*float64*); e 3) identificar automaticamente qual era o

trator e a atividade agrícola (exemplo: aração, transporte) através da leitura dos nomes das pastas onde os arquivos originais estavam salvos.

Para tornar viável a análise de todo o ciclo da safra sem exceder a memória do computador, o banco de dados consolidado foi salvo em um formato otimizado chamado *Apache Parquet*, utilizando a ferramenta *PyArrow* (The Apache Software Foundation, 2023). Essa estratégia garantiu uma eficiência de armazenamento muito superior às planilhas tradicionais, resultando em uma compressão de dados de aproximadamente 95%: o volume de arquivos caiu de 7,5 GB (formato bruto) para apenas 0,3 GB (formato processado). Isso permitiu que todas as operações matemáticas e estatísticas fossem realizadas de forma ágil.

Adicionalmente, previamente à caracterização descritiva do consumo de combustível, aplicou-se o método do intervalo interquartil (IQR) para remoção de valores atípicos (*outliers*) nos registros individuais de taxa de consumo (L/h). O procedimento foi executado de forma estratificada por trator, calculando-se, para cada modelo, o primeiro quartil (Q1) e o terceiro quartil (Q3) da variável *fuel_rate*, e definindo-se os limites de aceitação como $Q1 - 1,5 \times IQR$ e $Q3 + 1,5 \times IQR$, onde $IQR = Q3 - Q1$ (Tukey, 1977). Registros com valores de consumo fora desse intervalo foram excluídos da análise descritiva. A estratificação por trator justifica-se pela heterogeneidade de potência e perfil operacional da frota: um valor de consumo legítimo para o Fendt 820 (235 cv) seria atípico para o Fendt 211 (110 cv). A aplicação do filtro resultou na remoção de 34 registros (< 0,01% do total), indicando que a grande maioria dos dados brutos já se encontrava dentro de faixas fisicamente plausíveis; os poucos valores eliminados correspondiam a picos espúrios na leitura do sensor CAN, com magnitudes superiores a 3.200 L/h. Cabe ressaltar que esse procedimento foi aplicado exclusivamente para a geração das estatísticas descritivas (Tabelas 1 e 2); as análises inferenciais (ANOVA e teste de Tukey) utilizaram médias de blocos temporais agregados, que, pela própria natureza da agregação, já atenuam a influência de valores extremos isolados.

3.3. Definição e modelagem do estado de ociosidade

A definição de 'Ociosidade' (*Idling*) não é universal e depende do contexto agrônomo. Para este estudo, adotou-se uma abordagem conservadora e baseada em eventos. Diferente de abordagens puramente instantâneas, este trabalho considera

ociosidade apenas os eventos de parada que possuem persistência temporal, filtrando manobras operacionais curtas.

O estado da máquina S_t no instante t é classificado como Ocioso (1) ou Produtivo (0) seguindo uma lógica condicional composta:

$$S_t = \begin{cases} 1, & \text{se } (v_t < L_v) \wedge (n_{min} < n_t < n_{max}) \wedge (\Delta t_{evento} > L_t) \\ 0, & \text{caso contrário} \end{cases} \quad (1)$$

Onde (1):

- L_t e L_v : São os limiares de tempo e velocidade, respectivamente, utilizados para o corte e determinação do tempo ocioso.
- v_t : Velocidade de deslocamento. Comparada ao limiar $L_v = 0,75$ m/s (2,7 km/h). Este valor foi escolhido para filtrar ruídos de GPS (*drift*) e pequenos movimentos de acomodação, mas capturar paradas efetivas.
- n_{min} : Rotação mínima. Limite inferior de rotação para período ócio (100 RPM)
- n_t : Rotação instantânea. Leitura da rotação no instante de captura do sensor.
- n_{max} : Rotação máxima. Limite superior de rotação para período de ócio (1000 RPM).
- Δt_{evento} : Duração do evento. Comparada ao limiar temporal $L_t = 0$ segundos. Optou-se por uma abordagem de detecção instantânea para contabilizar todos os micro eventos de parada que satisfazem as condições físicas.

O consumo total de combustível em ociosidade C_{idle} foi calculado pela integração numérica da taxa de consumo ao longo do tempo, discretizada como uma Soma de Riemann:

$$C_{idle} = \sum_{i=1}^N (f_t \cdot \Delta t) \cdot S_t \quad (2)$$

Onde (2):

- C_{idle} : Volume total acumulado de combustível desperdiçado durante a safra.
- N : Número total de registro processados no conjunto de dados (aproximadamente 31 milhões de pontos).
- f_t : Taxa instantânea de consumo de combustível registrada no instante t (Litros/hora).
- Δt : Intervalo de tempo entre medições consecutivas. Dado a frequência de amostragem de 10 Hz, utiliza-se um valor constante de 0,1 segundo (convertido para $\approx 2,77 \times 10^{-5}$ horas para compatibilidade com a taxa de consumo)

- S_t : Variável binário de estado (0 ou 1), calculada anteriormente, que atua como um “filtro lógico”, zerando o consumo nos momentos produtivos e contabilizando-o apenas nos eventos de ociosidade confirmada.

Para a conversão dos dados físicos em métricas de negócio, assumiu-se o custo de diesel a € 1,588/L que era o preço médio de referência na Alemanha, local do estudo, para o período de 2024 e o fator de emissão de CO_2e (CO_2 equivalente) baseado nas diretrizes do IPCC e da EPA para óleo diesel padrão, considerando a queima completa.

Por fim, em conformidade com as práticas de Ciência Aberta e para garantir a auditabilidade e reprodutibilidade integral deste estudo, todo o código-fonte desenvolvido, incluindo os *scripts* de automação e a documentação para execução (seja em ambiente local ou em nuvem), foi disponibilizado publicamente. O repositório completo pode ser acessado, clonado e executado através do endereço eletrônico: <https://github.com/DTech1234/ALC-idletime>.

4. RESULTADO E DISCUSSÃO

4.1. Caracterização da amostra e análise estatística do consumo

A Tabela 1 sintetiza as estatísticas descritivas do consumo por trator e a Tabela 2 por atividade agrícola, calculadas sobre registros com motor ativo ($RPM \geq 100$) após remoção de valores atípicos pelo critério do intervalo interquartílico ($IQR \times 1,5$). O Fendt 722 e o Fendt 820, tratores de maior potência, apresentaram as maiores médias de consumo (17,20 e 17,68 L/h, respectivamente), enquanto o Fendt 211 registrou o menor consumo médio (4,37 L/h), reflexo direto de sua classe de potência e perfil de uso. O elevado coeficiente de variação observado nos tratores, principalmente para o Fendt 724 ($CV = 113,89\%$) e o Fendt 314 ($CV = 93,62\%$) evidencia padrões operacionais heterogêneos, com alternância entre longos períodos de ociosidade e operações de alta demanda, hipótese testada formalmente na sequência.

Tabela 1. Estatística descritiva do consumo de combustível (L/h) por trator Motor ativo ($RPM \geq 100$) | Outliers removidos pelo método $IQR \times 1,5$

Trator	N	Média	Mediana	Moda	DP	Mín.	Máx.	CV (%)
Fendt 211	1.554.432	4,37	3,75	1,5	2,92	0,0	13,25	66,88
Fendt 314	8.143.394	9,13	5,20	2,0	8,55	0,0	33,52	93,62
Fendt 722	11.135.639	17,20	14,10	0,0	12,81	0,0	45,30	74,43
Fendt 724	3.529.865	13,15	4,08	2,5	14,97	0,0	48,04	113,89
Fendt 820	3.955.424	17,68	17,10	2,0	12,76	0,0	40,00	72,18

Fonte: Elaborado pelo autor com dados de Götz et al. (2025). N = número de registros a 10 Hz; DP = desvio padrão; CV = coeficiente de variação; outliers removidos pelo critério $IQR \times 1,5$ aplicado por trator.

Tabela 2. Estatística descritiva do consumo de combustível (L/h) por atividade agrícola Motor ativo ($RPM \geq 100$) | Outliers removidos pelo método $IQR \times 1,5$

Atividade	N	Média	Mediana	Moda	DP	Mín.	Máx.	CV (%)
Aração	2.004.297	26,05	30,98	34,0	12,82	0,0	48,04	49,22

Atividade	N	Média	Mediana	Moda	DP	Mín.	Máx.	CV (%)
Cultivo profundo	1.791.306	25,60	28,00	39,0	13,58	0,0	47,92	53,03
Gradagem de disco	444.450	24,10	27,33	31,0	8,68	0,0	44,85	36,03
Semeadura conjugada	3.584.093	19,88	19,34	20,0	10,29	0,0	45,30	51,77
Grade rotativa	249.959	21,69	16,55	42,5	14,65	0,0	44,80	67,52
Prep. de canteiro	854.932	19,52	20,75	6,0	10,43	0,0	44,95	53,40
Cultivo superficial	554.093	18,48	20,40	26,0	9,03	0,0	44,85	48,89
Ceifagem grande	58.875	21,70	23,11	26,0	6,26	0,0	31,58	28,84
Trituração	995.619	14,90	13,30	11,0	7,36	0,0	45,05	49,43
Adubação	428.503	13,65	11,37	14,0	10,07	0,0	44,80	73,74
Grade rotativa	31.123	11,85	12,70	16,0	5,22	0,0	34,20	44,05
Transporte	1.051.265	9,53	4,57	2,0	10,98	0,0	47,84	115,24
Pulverização	221.584	7,10	6,91	8,0	3,48	0,0	29,35	48,98
Ceifagem frontal	17.100	9,35	9,08	9,0	1,68	0,0	22,19	17,98
Enleiramento	114.079	6,01	5,97	6,0	1,19	0,0	25,42	19,77
Semeadura de precisão	26.714	4,29	4,09	4,0	1,46	0,0	13,24	33,99
Ocioso/Parado	15.890.762	8,92	4,00	2,0	10,26	0,0	47,85	114,99


Fonte: Elaborado pelo autor com dados de Götz et al. (2025). Atividades ordenadas por média decrescente de consumo; N = número de registros a 10 Hz; DP = desvio padrão; CV = coeficiente de variação; outliers removidos pelo critério $IQR \times 1,5$ aplicado por trator.

A etapa de ingestão de dados consolidou um total de 881,4 horas de registros de telemetria. Após a filtragem técnica para remoção de períodos com o motor desligado ($RPM < 0$), obteve-se um volume analítico efetivo de 773,3 horas de operação com motor ativo, sobre as quais recaem as análises de consumo e eficiência energética.

A caracterização inicial da frota revelou forte heterogeneidade operacional (Figura 1). O trator Fendt 722 destacou-se como a unidade de maior demanda, acumulando 295,3 horas de motor ativo (38,1% do total), seguido pelo Fendt 820 (177,3 horas) e pelo Fendt

314 (163,8 horas). Na outra extremidade, o utilitário Fendt 211 representou a menor fração amostral, com 44,2 horas. Essa assimetria reflete a lógica operacional de frotas reais, nas quais tratores de tração pesada concentram a maior carga horária em operações de preparo de solo, enquanto utilitários leves desempenham funções intermitentes de apoio (Bochtis et al., 2014).

Figura 1. Dispersão do consumo horário de combustível (L/h) por modelo de trator da frota avaliada.



Fonte: Elaborado pelo autor com dados de Götz et al. (2025). *Nota:* O diamante vermelho representa a média aritmética; a linha horizontal interna na caixa representa a mediana. A variação vertical indica a amplitude dos dados operacionais reais (regime transiente).

Conforme descrito na Seção 3.1, a natureza serial dos dados de telemetria a 10 Hz exigiu tratamento prévio à aplicação de testes paramétricos. Registros consecutivos são altamente autocorrelacionados, pois o estado físico da máquina varia de forma contínua entre leituras adjacentes. A utilização direta de milhões de registros individuais como observações independentes inflaria artificialmente o poder estatístico, resultando em p-valores artificialmente baixos e na detecção de diferenças sem relevância prática (Hurlbert, 1984).

Para contornar essa limitação, os registros foram agregados em blocos de 8 horas (288.000 registros a 10 Hz), representativos de uma jornada operacional completa. Cada bloco constitui uma unidade experimental cuja independência é sustentada pela descontinuidade natural entre jornadas de trabalho, e cuja média de consumo (L/h) sintetiza o comportamento integrado da máquina ao longo de um ciclo diário. O delineamento adotado foi o Inteiramente Casualizado (DIC), com balanceamento por subamostragem aleatória, de forma que todos os tratamentos apresentassem o mesmo número de repetições ($n = 5$), condição que garante equidade de poder estatístico entre os grupos (Virtanen et al., 2020; Seabold; Perktold, 2010).

A Análise de Variância aplicada ao consumo médio dos cinco modelos de tratores indicou diferenças altamente significativas ($F = 25,02$; $p < 0,001$; $\alpha = 0,001$). O teste de comparação múltipla de Tukey HSD permitiu estratificar a frota em grupos parcialmente sobrepostos (Tabela 3), revelando um gradiente de consumo coerente com a classe de potência e a função operacional de cada máquina.

Tabela 3. Comparação múltipla de médias de consumo de combustível (L/h) por trator, em delineamento inteiramente casualizado com blocos de 8 horas; teste de Tukey HSD; $\alpha = 0,001$; $n = 55$ blocos por tratamento.

Trator	Função Principal	Média de consumo (L/h)	Grupo
Fendt 722	Tração pesada	$21,83 \pm 3,55$	a
Fendt 820	Tração Pesada	$14,73 \pm 4,04$	ab
Fendt 724	Suporte/Logística	$11,98 \pm 2,64$	bc
Fendt 314	Utilitário Médio	$8,81 \pm 2,16$	bcd
Fendt 211	Utilitário Leve	$4,57 \pm 1,25$	cde

Fonte: Elaborado pelo autor com dados de Götz et al. (2025). *Nota:* Médias seguidas por letras distintas na coluna "Grupo" diferem estatisticamente entre si ($p < 0,0001$).

Diferentemente de análises baseadas em registros individuais, nas quais o elevado poder estatístico tende a separar todos os tratamentos em grupos distintos, o agrupamento em jornadas operacionais revelou sobreposições agronomicamente coerentes. Os modelos Fendt 722 (grupo "a") e Fendt 820 (grupo "ab"), ambos de tração pesada com potência nominal superior a 150 kW, compartilham a letra "a", indicando que, na escala de uma jornada de trabalho, seu consumo médio não difere estatisticamente. Este resultado é consistente com Grisso et al. (2004), que demonstraram que o consumo horário é primariamente governado pela demanda de potência na barra de tração, e não pela potência nominal do motor isoladamente.

Na faixa intermediária, o Fendt 724 (grupo "bc") apresenta sobreposição parcial tanto com o Fendt 820 (grupo "ab") quanto com o utilitário médio Fendt 314 (grupo "bcd"), refletindo sua função híbrida de suporte e logística, alternando entre tarefas de campo de média exigência e transporte. O utilitário leve Fendt 211 (grupo "cde") diferiu dos tratores de tração pesada, com consumo médio de apenas 4,57 L/h, coerente com sua utilização predominante em atividades de baixa demanda energética.

A variabilidade intragrupo, expressa pelos desvios-padrão (3,55 a 4,04 L/h nos tratores pesados), reflete a diversidade de operações executadas por cada trator ao longo das jornadas, um mesmo Fendt 722 pode ter arado durante 6 horas e transportado implementos durante 2 horas no mesmo bloco. Esta variabilidade, longe de representar ruído amostral, é uma característica intrínseca de dados operacionais coletados em regime transiente real, como documentado por Lovarelli e Bacenetti (2019) em campanhas de monitoramento via CAN Bus em frotas europeias.


A mesma abordagem estatística foi aplicada às atividades agrícolas registradas no dataset. Neste experimento, adotou-se um bloco de 4 horas (144.000 registros), uma vez que diversas atividades não acumulam uma jornada completa de 8 horas ao longo da safra. Foram excluídas atividades com menos de 5 blocos completos, resultando em sete atividades remanescentes. A ANOVA indicou diferenças altamente significativas ($F = 14,90$; $p < 0,001$; $\alpha = 0,001$). O teste de Tukey HSD (Tabela 4) e a análise de dispersão (Figura 2) revelaram uma estratificação gradual do consumo em função da demanda de potência.

Tabela 4. Consumo médio de combustível (L/h) por atividade agrícola e agrupamento estatístico em DIC com blocos de 8 horas; teste de Tukey HSD; $\alpha = 0,001$; $n = 14$ blocos por tratamento.

Atividade Agrícola	Consumo Médio $\pm$ DP (L/h)	Grupo
Aração	29,23 $\pm$ 4,36	a
Cultivo Profundo	25,59 $\pm$ 8,14	ab
Semeadura Conj.	20,48 $\pm$ 5,53	abc
Prep. Canteiro	19,79 $\pm$ 1,97	abcd
Trituração	14,76 $\pm$ 3,81	bcde
Transporte	9,55 $\pm$ 1,10	cdef
Ocioso/Parado	8,16 $\pm$ 3,15	cdefg

Fonte: Elaborado pelo autor com dados de Götz et al. (2025). *Nota:* Médias seguidas por ao menos uma letra em comum não diferem, estatisticamente, entre si (Tukey HSD; $p > 0,0001$). Atividades com menos de 10 blocos de 8 horas excluídas da análise.

Figura 2. Variabilidade do consumo de combustível (L/h) por atividade agrícola da frota avaliada.



Fonte: Elaborada pelo autor com dados de Götz et al. (2025). Ordenadas por consumo médio decrescente

O padrão de letras compartilhadas entre atividades adjacentes descreve um gradiente contínuo de demanda energética que se organiza em três faixas funcionais:

Faixa 1 - Operações de alta demanda (grupos a–ab; 25 a 29 L/h): Compreende Aração (29,23 L/h) e Cultivo Profundo (25,59 L/h), atividades com engajamento total do solo que exigem tração máxima na barra de engate. Os valores observados são coerentes com a literatura: Grisso e Pitman (2001) reportaram consumos de 20 a 30 L/h para operações de preparo primário de solo em tratores de classe semelhante.

Faixa 2 - Operações de demanda intermediária (grupos abc–bcde; 15 a 20 L/h): Agrupa Semeadura Conj. (20,48 L/h), Preparação de Canteiro (19,79 L/h) e Trituração (14,76 L/h). Estas operações envolvem implementos de menor profundidade de trabalho ou menor resistência ao avanço, demandando tipicamente 40 a 60% da potência disponível. A sobreposição estatística entre Semeadura Conj. e Prep. Canteiro confirma que operações com demanda de potência semelhante convergem para faixas de consumo indistinguíveis.

Faixa 3: Operações não produtivas (grupos cdef–cdefg; 8 a 10 L/h): Transporte (9,55 ± 1,10 L/h) e Ocioso/Parado (8,16 ± 3,15 L/h) apresentam os menores consumos médios e são estatisticamente indistinguíveis entre si. Este achado é particularmente relevante para a análise de ociosidade desenvolvida nas seções subsequentes: mesmo em escala de meia jornada, o tempo classificado como "Ocioso/Parado" consome diesel em taxa comparável ao transporte, confirmando que o tempo de motor ativo sem trabalho agrônômico constitui uma fonte concreta e mensurável de desperdício de combustível. Perozzi et al. (2016) demonstraram, em estudo com 61 tratores New Holland T9, que a ociosidade pode consumir mais de 20% do tempo de vida operacional da máquina, e Molari et al. (2019) identificaram que 67% dos eventos de ociosidade em uma frota

monitorada eram atribuíveis ao comportamento do operador, evidenciando que parte significativa desse consumo é passível de mitigação por intervenção comportamental.


4.2. Análise global da frota e eficiência operacional

O *pipeline* de Engenharia de Dados processou a totalidade dos arquivos brutos disponíveis, aplicando rotinas de limpeza e de-duplicação para eliminar as redundâncias inerentes à coleta de dados fragmentada. Este processo resultou em um volume analítico efetivo de 881,4 horas de operação consolidada, correspondendo a mais de 31 milhões de registros de telemetria únicos. A aplicação do algoritmo de classificação baseado em eventos identificou 163,0 horas de tempo ocioso, resultando em um Índice de Ociosidade Global de 18,5%.

É importante notar que o volume analítico final obtido neste estudo (881,4 horas) apresenta uma discrepância positiva de aproximadamente 2% em relação aos totais reportados originalmente pelos autores do dataset de 861,5 horas (Götz et al., 2025). Essa diferença não denota inconsistência, mas sim uma decisão metodológica intencional referente à arquitetura de ingestão de dados.

Enquanto os autores disponibilizaram parte dos dados pré-processados em formato *Pickle* (.pkl), um método de serialização nativo do Python que frequentemente implica na filtragem prévia de registros com tipagem inconsistente ou ruído de sensores, nosso pipeline optou pelo reprocessamento integral dos arquivos brutos (.csv) convertidos para o formato Apache Parquet. Ao utilizar o motor *PyArrow*, que suporta *schema evolution* e tipos nulos (*nullable types*) sem o descarte imediato de linhas (Apache, 2023), preservou-se a integridade total da série temporal, incluindo registros de borda e sequências de desligamento (*shutdown*) que metodologias tradicionais tendem a descartar como ruído. Desta forma, o cálculo de consumo baseou-se na 'vida digital completa' da máquina, garantindo que nenhum intervalo de operação, por menor que fosse, fosse excluído da auditoria, preservando quase 20 horas a mais de operação (Figura 3).

Figura 3: Balanço operacional global: distribuição percentual do tempo de atividade (esquerda) e a respectiva participação no consumo total de combustível (direita).



Fonte: Elaborada pelo autor com dados de Götz et al. (2025) *Nota:* No gráfico de tempo (esquerda), a cor cinza ("Desligado") indica períodos de telemetria ativa sem rotação do motor. No gráfico de consumo (direita), observa-se apenas o combustível queimado com motor ativo, onde a área vermelha ("Ocioso") representa o volume de diesel desperdiçado em ineficiências logísticas, em contraste com o uso produtivo em verde ("Trabalhando").

Este resultado corrobora os achados da literatura especializada, situando-se dentro do intervalo crítico observado em operações mecanizadas de alta tecnologia. Pesquisadores da Universidade de Bologna, na Itália, analisaram dados de barramento CAN de 61 tratores, reportaram taxas de ociosidade variando amplamente entre 10% e 43% (Perozzi et al., 2016), dependendo da tarefa, com uma média global próxima a 17% (Molari et al., 2019). Este resultado apresenta uma convergência notável com a literatura europeia recente. Essa estabilidade em torno de 20% sugere um padrão operacional intrínseco à agricultura europeia, onde a fragmentação de terras e a proximidade da infraestrutura impõem um ritmo específico de paradas técnicas e logísticas.

Por outro lado, autores analisando operações no Cerrado brasileiro, reportou índices de ociosidade próximos a 25% (Santos, 2023). A diferença desses poucos pontos percentuais em relação aos nossos dados Alemanha, 7% (calculados pelo autor com *dataset* de Götz et al., 2025) e aos da Itália 5% (Molari et al., 2019) pode ser explicada pelas diferenças na escala e logística. As grandes extensões brasileiras impõem desafios de

abastecimento e comboio (logística de sementes e fertilizantes) que podem forçar tempos de espera mais longos do que nas propriedades europeias, mais fragmentadas e próximas à infraestrutura da fazenda.

A magnitude do desperdício identificado neste estudo (453,9 L e 163,0 h ociosas) refere-se a uma estação experimental de aproximadamente 355 hectares, operando cinco tratores durante uma única safra europeia. Para dimensionar o impacto potencial no contexto brasileiro, é necessário considerar a diferença de escala. O Censo Agropecuário de 2017 registrou 1,23 milhão de tratores em 734 mil estabelecimentos no Brasil (IBGE, 2019), e grupos como a SLC Agrícola operam atualmente mais de 670 mil hectares distribuídos em 22 unidades de produção, com fazendas individuais que ultrapassam 40 mil hectares e demandam frotas com dezenas de máquinas por unidade. Nessa escala, um único dia de operação de uma fazenda corporativa brasileira pode consumir volume de diesel equivalente ao que a frota em TUM consumiu ao longo de toda a safra analisada, mais de 11 mil litros de diesel. Se o índice de ociosidade reportado por Santos (2023) para o Cerrado ($\approx 25\%$) for representativo dessas operações de larga escala, as perdas anuais em combustível, emissões de CO₂ e desgaste mecânico assumem proporções economicamente expressivas, reforçando a urgência de diagnósticos quantitativos como o proposto neste trabalho.

Cabe ressaltar que, até o momento da elaboração desta pesquisa, não foi identificado nenhum conjunto de dados telemétricos de tratores agrícolas brasileiros disponível publicamente com a granularidade temporal (10 Hz) e a rastreabilidade de atividades oferecidas pelo *Agricultural Load Cycles* (Götz et al., 2025). Essa lacuna não invalida a análise; ao contrário, reforça sua relevância. O *pipeline* determinístico aqui desenvolvido, por ser baseado exclusivamente em variáveis físicas universais do barramento CAN (rotação do motor e velocidade de deslocamento), é intrinsecamente agnóstico à geografia e à marca da máquina, podendo ser replicado sobre dados telemétricos de qualquer frota equipada com ISOBUS ou J1939. A ausência de um equivalente brasileiro público constitui, portanto, não uma limitação metodológica, mas uma oportunidade concreta para que fabricantes, cooperativas e grandes operações agrícolas nacionais adotem protocolos semelhantes de coleta e abertura de dados, viabilizando estudos futuros calibrados para as condições específicas do Cerrado, do Pampa e das demais fronteiras agrícolas do país.

Ao decompor a análise global para o nível de unidade individual, emerge uma notável heterogeneidade no comportamento operacional da frota (Tabela 5). Observa-se uma relação inversa entre a intensidade de uso e o índice de ociosidade.


Tabela 5: Consumo de combustível e indicadores de desperdício por unidade da frota monitorada.

Trator	Consumo Total (L)	Desperdício Global
Fendt 211	208,6	26,5 L (12,7%)
Fendt 724	1.289,2	124 L (9,6%)
Fendt 314	2.066,3	148,3 L (7,2%)
Fendt 820	1.959,7	54,6 L (2,8%)
Fendt 722	5.786,3	100,6 L (1,7%)

Fonte: Elaborada pelo autor com dados de Götz et al. (2025).

Figura 4: "Eficiência energética da frota: diagrama hierárquico (*Sunburst*) relacionando o consumo absoluto (tamanho) e o índice de ineficiência (cor) por trator e atividade.

Raio-X da Eficiência: Tamanho = Consumo Total | Cor = % Desperdício



Nota: O centro representa a unidade (trator) e o anel externo a atividade realizada. Áreas maiores indicam maior consumo total de diesel. A escala de cores varia do verde (alta eficiência) ao vermelho (alto desperdício em ociosidade), permitindo a identificação imediata dos gargalos operacionais (exemplo: segmentos grandes e vermelhos).

O trator Fendt 722, responsável pelo maior volume de trabalho da safra (consumo total de 5.786,3 L), apresentou a maior eficiência energética do grupo, com apenas 1,7% de desperdício (Figura 4). Este comportamento é característico de máquinas destinadas a operações de preparo primário e tração pesada (*Heavy Draft*), onde o motor opera majoritariamente em regimes de carga constante e otimizada, minimizando os tempos mortos relativos (Grisso; Pitman, 2001).

Em contrapartida, o trator Fendt 211, de menor potência e utilizado predominantemente em tarefas de suporte, registrou um índice de ociosidade de 12,7%, apesar de seu baixo consumo absoluto. Esse fenômeno ilustra o gargalo logístico apontado por autores em sistemas de tráfego controlado: máquinas auxiliares frequentemente permanecem em espera (*waiting times*) aguardando o sincronismo com colhedoras ou unidades de transbordo (Bochtis et al., 2014). Embora represente um volume menor de diesel (26,5 L), essa ineficiência aponta para uma subutilização do ativo, onde a depreciação horária continua a acumular mesmo sem produção efetiva (Edwards et al., 2015).

4.3. Cenários de mitigação e impacto ambiental.

Aprofundando a análise para a dimensão das atividades, a visualização hierárquica dos dados (Figura 4) revela que a categoria “Geral” (*Not Working*) e as operações de Transporte respondem pela maior parte do desperdício acumulado. No caso dos tratores Fendt 724 e 820, a atividade classificada como “Geral” (*Not Working* no *dataset*) foi responsável por mais de 50% do consumo total dessas unidades, com um desperdício intrínseco variando entre aproximadamente 2% e 12% na frota em geral.

Essa predominância de consumo em estados não produtivos corrobora a hipótese de que a gestão ineficiente de frotas em deslocamento são os principais vetores de consumo oculto. Em ciclos agrícolas europeus, o transporte rodoviário entre talhões fragmentados pode consumir até 35% do tempo total, criando "tempos de oportunidade" para ociosidade que não existiriam em operações contínuas de campo (Perozzi et al., 2016). Portanto, a estratégia de mitigação não deve focar na tecnologia do motor, que já se provou eficiente no Fendt 722, mas sim no planejamento logístico e na conscientização operacional das tarefas auxiliares.

Esta redução de emissões via eficiência operacional é crítica. Revisando tecnologias de controle de poluentes em máquinas agrícolas, autores destacam que, embora a evolução dos motores (Tier 4/Stage V) tenha mitigado drasticamente a emissão de material particulado e óxidos de nitrogênio (Nox), a redução de CO_2 permanece diretamente atrelada ao consumo de combustível (Silveira et al., 2023). Portanto, minimizar o tempo ocioso atua como uma estratégia complementar indispensável às tecnologias de pós-tratamento de gases, atacando a fonte da emissão e não apenas seu

produto final. Cenários mais agressivos, que exigiriam tecnologias embarcadas como sistemas *Start-Stop* ou hibridização, ampliariam esse ganho ambiental para quase 1 tonelada de CO_2e evitada na safra. Cabe ressaltar que os equipamentos que mais gastaram diesel nesse cenário são aqueles que tiveram índices de desperdício mínimos, dificilmente evitáveis, demonstrando alguns equipamentos podem já ter atingido alto índice de gestão.

A projeção de cenários evidenciou que metas conservadoras de mitigação (redução de 25% na ociosidade) poderiam ser atingidas via gestão comportamental, gerando economia imediata de recursos e redução nas emissões de gases de efeito estufa (Silveira et al., 2023). Contudo, o estudo revelou uma barreira crítica na escalabilidade dos métodos atuais: a opacidade semântica da categoria “Geral” (*Not Working*). Embora algoritmos determinísticos quantifiquem com precisão física o tempo de parada, a qualificação do *motivo* da ociosidade permanece inacessível em dados históricos sem anotação prévia.

A redução do tempo ocioso transcende a economia financeira imediata, posicionando a gestão de frotas como um componente estratégico na descarbonização da agricultura. Outros autores, ao analisarem a ALC de operações mecanizadas, identificam que o consumo de combustível fóssil representa frequentemente o principal impacto ambiental (*hotspot*) na produção de culturas extensivas (Lovarelli, Bacenetti, 2019).

Neste contexto, a mitigação de 0,3 toneladas de CO_2e (cenário conservador) a 0,9 toneladas (cenário otimizado) por safra, apenas através do controle da ociosidade, valida a eficiência operacional como uma ferramenta de agricultura de baixo carbono. Diferente do sequestro de carbono no solo, que exige anos para ser mensurado, a redução de emissões por eficiência de combustível é imediata e auditável.

Para o produtor rural, isso abre portas para a monetização via créditos de descarbonização, como os CBIOS no programa RenovaBio no Brasil (BRASIL, 2017), ou prêmios de sustentabilidade em *commodities* certificadas. Sob a ótica da governança corporativa (ESG), a demonstração de um *pipeline* de dados capaz de auditar e reduzir a pegada de carbono da frota valoriza o ativo biológico e alinha a propriedade às metas climáticas globais estabelecidas pela FAO (2023) que preconiza a eficiência energética como pilar central para a resiliência dos sistemas agroalimentares.

A viabilidade dessas metas, contudo, depende do controle da categoria "Geral" (*Not Working*), que registrou os maiores índices absolutos de desperdício na análise

segmentada (Figura 4). A predominância desta categoria, atuando como um "guarda-chuva" para quase 90% do tempo ocioso, evidencia um desafio estrutural da Agricultura Digital: a incerteza contextual (Paraforos, Griepentrog, 2019).

4.4. Oportunidade de aperfeiçoamento metodológico.

Enquanto paradas para ajustes técnicos são inevitáveis, a falta de distinção semântica nos dados de telemetria entre "espera logística" (exemplo: aguardando transbordo) e "ociosidade discricionária" (ex.: climatização da cabine) mascara a verdadeira ineficiência. Nosso algoritmo determinístico classifica corretamente o estado físico da máquina (parada), mas carece de *inputs* sobre a intenção da operação. Isso sugere que a próxima fronteira de eficiência não reside apenas em sensores mais precisos, mas na implementação de sistemas de anotação automática ou interfaces homem-máquina que contextualizem essas paradas em tempo real, permitindo uma gestão logística mais assertiva (Bochtis et al., 2014).

A rotulagem manual retrospectiva é inviável em larga escala, dada a inexistência de uma "verdade de campo" (*Ground Truth*) universal capaz de explicar as nuances operacionais de diferentes fabricantes e realidades produtivas. A variabilidade dos sinais entre marcas e modelos impede a criação de um classificador estático único. Desta forma, a superação desse gargalo tecnológico aponta para a necessidade de descentralizar a inteligência de dados, capacitando o próprio sistema produtivo a gerar seus rótulos. A evolução natural desta abordagem reside no desenvolvimento de ferramentas de Aquisição de Dados com Rotulagem Contextual Ágil, permitindo que cada propriedade rural, independentemente de seu porte ou da marca de sua frota, treine seus próprios modelos de reconhecimento de padrões (*custom models*). Ao integrar a coleta de *inputs* do operador em tempo real com técnicas de Aprendizado Semi-Supervisionado (Li et al., 2022), torna-se possível traduzir o "idioma" específico de cada máquina em alertas de gestão instantâneos via IoT. Essa mudança de paradigma, saindo da análise passiva para a aprendizagem ativa, é o passo fundamental para democratizar a eficiência energética na Agricultura 4.0.

Adicionalmente, a barreira da rotulagem de dados massivos aponta para a oportunidade de desenvolvimento de plataformas de anotação colaborativa (*Crowdsourcing*). O desenvolvimento de tais ferramentas no ambiente acadêmico fomentaria a interdisciplinaridade, servindo como vetor de aprendizado prático para discentes de Agronomia e Ciência da Computação. Autores alertam que a competitividade global do agronegócio dependerá cada vez menos apenas da tecnologia *per se*, e mais do letramento de dados (*Data Literacy*) dos profissionais do campo (Wolfert et al., 2017). Portanto, integrar a ciência de dados ao currículo agrônomo não é apenas uma necessidade acadêmica, mas um imperativo estratégico para garantir que a próxima geração de gestores rurais brasileiros domine a complexidade dos sistemas digitais.

Finalmente, ainda que a aplicabilidade comercial imediata deste *software* possa ser restrita às especificidades da frota que o originou, seu valor transcende a utilidade operacional, consolidando-se como um poderoso instrumento pedagógico. A estruturação deste *pipeline* oferece a docentes e pesquisadores um 'laboratório vivo' para a demonstração prática de competências críticas na formação contemporânea, abrangendo desde a arquitetura de Big Data e processamento paralelo, até os fundamentos de Machine Learning e conceitos de anotação de dados. A disponibilização deste código em ambientes de colaboração aberta, como GitHub e Hugging Face, não apenas fomenta a transparência científica, mas atua como um catalisador para o letramento digital (*Digital Literacy*) da classe agrônoma. Autores destacam que essa competência híbrida é urgente para evitar a exclusão tecnológica, capacitando os futuros profissionais a transitarem com fluidez e autonomia entre a realidade do campo e a lógica do código (Klerkx et al., 2019).

CONCLUSÃO

Este estudo confirmou a hipótese de que frotas agrícolas mecanizadas acumulam um tempo ocioso significativo (18,5%) que permanece oculto em análises gerenciais convencionais, demonstrando que o emprego de um *pipeline* de Engenharia de Dados capaz de processar milhões de registros de telemetria é eficaz para diagnosticar ineficiências latentes. A análise granular revelou que essa ociosidade é heterogênea, sendo crítica em unidades auxiliares como o Fendt 211 (12,7% de desperdício) em comparação à eficiência otimizada de tratores de alta potência, o que ressalta a urgência do letramento digital para que profissionais da agronomia transformem dados brutos em decisões estratégicas de gestão. Conclui-se que a mitigação desse desperdício transcende a economia financeira imediata, consolidando a otimização energética da frota como uma ferramenta de sustentabilidade auditável que reduz a pegada de carbono e habilita o produtor rural a acessar mercados de créditos de descarbonização, transformando efetivamente a eficiência de dados em um ativo ambiental estratégico.

REFERÊNCIAS

APACHE SOFTWARE FOUNDATION. **Apache Arrow**: A cross-language development platform for in-memory data. 2023. Disponível em: <https://arrow.apache.org/>. Acesso em: 23 mar. 2025.

BRASIL. **Lei nº 13.576, de 26 de dezembro de 2017**. Dispõe sobre a Política Nacional de Biocombustíveis (RenovaBio) e dá outras providências. Diário Oficial da União: seção 1, Brasília, DF, ano 154, n. 247, p. 1-4, 27 dez. 2017.

BRASIL. Conselho Nacional do Meio Ambiente (CONAMA). *Resolução nº 433, de 13 de julho de 2011*. Dispõe sobre o controle das emissões de poluentes e ruídos em máquinas agrícolas e rodoviárias automotrizes. Diário Oficial da União, Brasília, 2011.

BOCHTIS, D. D.; SØRENSEN, C. G.; BUSATO, P. Advances in agricultural machinery management: A review. **Biosystems Engineering**, v. 126, p. 69–81, 2014. DOI: 10.1016/j.biosystemseng.2014.07.012.

CSS ELECTRONICS. **J1939 Explained – A Simple Intro**. 2025. Disponível em: <http://csselectronics.com/pages/j1939-explained-simple-intro-tutorial>. Acesso em: abr. 2025.

EDWARDS, W.; AYRES, G.; BOEHLJE, M. **Estimating Farm Machinery Costs**. Revised. Ames, IA: Cooperative Extension Service, Iowa State University of Science and Technology, ago. 2015. (Machinery Management, PM 710).

FAO. Greenhouse gas emissions from agrifood systems. Global, regional and country trends, 2000–2021. **Food and Agriculture Organization of the United Nations**. Rome, 2023

GÖTZ, K.; KUSUMA, A.; DÖRFLER, A.; LIENKAMP, M. **Agricultural Load Cycles: Tractor Mission Profiles From Recorded GNSS and CAN Bus Data**. Versão 1.0. Zenodo, 2025. 1 conjunto de dados. DOI: <https://doi.org/10.5281/zenodo.14619787>.

GRISSE, R.; PITMAN, R. M. Gear up and throttle down – saving fuel. **Virginia Cooperative Extension**, Virginia State University, Publication 422-450 (BSE-326P), 2001.

GRISSE, R. D.; KOCHER, M. F.; VAUGHAN, D. H. Predicting tractor fuel consumption. **Applied Engineering in Agriculture**, v. 20, n. 5, p. 553–561, 2004. DOI: 10.13031/2013.17455.

HURLBERT, S. H. Pseudoreplication and the Design of Ecological Field Experiments. **Ecological Monographs**, v. 54, n. 2, p. 187–211, 1984. DOI: 10.2307/194266

IBAMA. Ofício nº 2439/2025/GABIN. Proposta de regulamentação da Fase PROCONVE MAR-II para máquinas agrícolas e rodoviárias. Processo SEI 02001.035737/2025-25. Brasília: Instituto Brasileiro do Meio Ambiente e dos Recursos Naturais Renováveis, nov. 2025.

IBGE – INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA. Censo Agropecuário 2017: resultados definitivos. Rio de Janeiro: IBGE, 2019. Disponível em: <https://censoagro2017.ibge.gov.br/>. Acesso em: 15 jan. 2026.

KEY, N. Farm size and productivity growth in the United States Corn Belt. **Food Policy**, [s.l.], v. 84, p. 186-195, 2019. DOI: <https://doi.org/10.1016/j.foodpol.2018.03.017>.

KLERKX, L.; JAKKU, E.; LABARTHE, P. A Review of social science on digital agriculture, smart farming and agriculture 4.0: New contributions and a future research agenda. **NJAS – Wageningen Journal of Life Sciences**, v. 90-91, 100315, 2019. DOI: 10.1016/j.njas.2019.100315.

LATTZ, D.; SCHNITKEY, G.; PAULSON, N.; ZULAUF, C. Machinery Cost Estimates: Tractor Costs. Department of Agricultural and Consumer Economics, University of Illinois at Urbana-Champaign, 2025. Disponível em: <https://farmdoc.illinois.edu/management>. Acesso em: mar. 2026.

LI, Y.; ZHAO, B.; ZHANG, W.; ZHOU, L. Evaluation of agricultural machinery operational benefits based on semi-supervised learning. **Agriculture**, [s.l.], v. 12, n. 12, p. 2075, 2022. DOI: <https://doi.org/10.3390/agriculture12122075>.

LOVARELLI, D.; BACENETTI, J. Bridging the gap between reliable farm data and environmental sustainability assessment of agricultural operations. **Biosystems Engineering**, v. 183, p. 24-34, 2019.

LOVARELLI, D.; FIALA, M.; LARSSON, G. Fuel consumption and exhaust emissions during on-field tractor activity: A possible improving strategy for the environmental load of agricultural mechanisation. **Computers and Electronics in Agriculture**, v. 151, p. 238–248, 2018. DOI: 10.1016/j.compag.2018.06.008.

MATTETTI, M.; BELTRAMIN, A.; PEREZ ESTEVEZ, M. A.; VARANI, M.; RENZI, M.; ALBERTI, L. Start and stop systems on agricultural tractors as solution for saving fuel and emissions. **Biosystems Engineering**, v. 219, p. 87–100, 2022. DOI: <https://doi.org/10.1016/j.biosystemseng.2022.02.006>.

MOLARI, G; MATTETTI, M.; LEZINI, N; FIORATI, S. An update methodology to analyse the idling of agricultural tractors. **Biosystems Engineering**, v. 187, 160-170, 2019. DOI: <https://doi.org/10.1016/j.biosystemseng.2019.09.001>

MCKINNEY, W. Data Structures for Statistical Computing in Python. In: **Proceedings of the 9th Python in Science Conference**, p. 56–61, 2010.

PARAFOROS, S. D.; GRIEPENTROG, H. W. Tractor fuel rate modeling and simulation using switching Markov chains on CAN-Bus data. **IFAC-PapersOnLine**, [s.l.], v. 52, n. 30, p. 379-384, 2019. DOI: <https://doi.org/10.1016/j.ifacol.2019.12.580>.

PARLAMENTO EUROPEU; CONSELHO DA UNIÃO EUROPEIA. Regulamento (UE) 2016/1628. Requisitos relativos aos limites de emissão de poluentes gasosos e particulados e à homologação de motores de combustão interna para máquinas móveis não rodoviárias. *Jornal Oficial da União Europeia*, L 252/53, Bruxelas, set. 2016. Acessado em 13-03-2026 <https://eur-lex.europa.eu/eli/reg/2016/1628/oj/eng>

PEROZZI, D.; MATTETTI, M.; MOLARI, G.; SERENI, E. Methodology to analyse farm tractor idling time. **Biosystems Engineering**, [s.l.], v. 148, p. 81-89, 2016. DOI: <https://doi.org/10.1016/j.biosystemseng.2016.05.007>.

PYTHON SOFTWARE FOUNDATION. **concurrent.futures**, **Launching parallel tasks**. Python 3.11 Documentation. 2023. Disponível em: <https://docs.python.org/3/library/concurrent.futures.html>. Acesso em: 23 mar. 2025.

SANTOS, K. F. dos. **Telemetria: análises sobre potencialidades e desafios na Região Central do Brasil**. 2023. Trabalho de Conclusão de Curso (Graduação em Engenharia Agrícola) – Universidade Federal de Viçosa, Viçosa, 2023. Disponível em: <https://locus.ufv.br/server/api/core/bitstreams/44bb64c0-2ac7-48f5-bc99-18cfbc4eed77/content>. Acesso em: abr. 2025.

SEABOLD, S.; PERKTOLD, J. Statsmodels: Econometric and Statistical Modeling with Python. In: *Proceedings of the 9th Python in Science Conference (SciPy 2010)*, Austin, Texas, p. 92–96, 2010. DOI: 10.25080/Majora-92bf1922-011

SILVEIRA, F. da; MACHADO, F. M.; FARIAS, M. S. de; SCHLOSSER, J. F. Fuel consumption by agricultural machinery: a review of pollutant emission control technologies. **Ciência Rural**, Santa Maria, v. 53, n. 5, 2023. DOI: <https://doi.org/10.1590/0103-8478cr20220029>.

SLC AGRÍCOLA S.A. Relatório Anual Safra 2023/2024. Porto Alegre, 2024. Disponível em: <https://www.slcagricola.com.br/>. Acesso em: 16 jan. 2026

TUKEY, J. W. *Exploratory Data Analysis*. Reading, MA: Addison-Wesley, 1977.

U.S. EPA. *Control of Emissions of Air Pollution from Nonroad Diesel Engines and Fuel*. Final Rule. 40 CFR Parts 9, 69, 80 e 1039. Washington, D.C.: United States Environmental Protection Agency, 2004.

VIRTANEN, P., GOMMERS, R., OLIPHANT, T.E., HABERLAND, M., REDDY, T., COURNAPEAU, D., BURBER, E., van der WALT, S.J., BRETT, M., WILSON, J., MILLMAN, K.J., MAYOROV, N., NELSON, A.R.J., JONES, E., KERN, R., LARSON, E., CAREY, C.J., POLAT, İ., FENG, Y., MOORE, E.W., VANDERPLAS, J., LAXALDE, D., PERKTOLD, J., CIMRMAN, R., HENRIKSEN, I., QUINTERO, E.A., HARRIS, C.R., ARCHIVALD, A.M., RIBEIRO, A.H., PEDREGOSA, F., van

MULBREGT, P. & SciPy 1.0 Contributors. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python. *Nature Methods*, v. 17, p. 261–272, 2020. DOI: 10.1038/s41592-019-0686-2

WOLFERT, S.; GE, L.; VERDOUW, C.; BOGAARDT, M. J. Big data in smart farming – a review. **Agricultural Systems**, v. 153, p. 69-80, 2017. DOI: 10.1016/j.agsy.2017.01.023.

APÊNDICES

APÊNDICE A – PRODUTO TÉCNICO TECNOLÓGICO

TÍTULO: Certificado de Registro de Programa de computador Processo BR512026000883-2

TIPO DE PRODUTO: Determinador de ociosidade de máquinas agrícolas

DATA: 09/02/2026

RESUMO TÉCNICO: Pipeline determinístico de Engenharia de Dados desenvolvido em Python para diagnóstico de ineficiência operacional em frotas agrícolas. Consolida milhões de registros telemétricos provenientes de arquivos brutos de telemetria de tratores agrícolas, via processamento paralelo e dicionário canônico de padronização de variáveis CAN Bus. Classifica estados operacionais (ocioso vs. produtivo) por limiares físicos de velocidade ($<0,75$ m/s) e rotação de motor sem carga (100–1000 RPM), quantificando o consumo em ociosidade por integração numérica (Soma de Riemann). Armazena em Apache Parquet com compressão de 95%.

REPOSITÓRIO: <https://github.com/DTech1234/ALC-idletime>

OUTROS DETALHES: Código aberto, reproduzível e agnóstico a marca/geografia.

FINALIDADE: Permitir auditoria de dados em frotas agrícolas de pequenos, médios e grandes produtores ou grupos agrícolas.

IMPACTO: Desconhecido

Nível: Desconhecido

Demanda: Desconhecida

Objetivo da pesquisa: Criar pipeline para diagnóstico de desperdício de combustíveis em equipamentos agrícolas (Tratores, colhedoras, pulverizadores).

Área impactada pela produção: Socioeconômica e ambiental.

Tipo: Democratização de acesso e processamento de dados de telemetria

Descrição do tipo de impacto: Permite gestores rurais de investigarem possíveis momentos de ócio improdutivo para tomada de ação rápida e estratégica visando reduzir o uso de recursos escassos, aumentando a competitividade econômica do negócio rural.

Seu uso reduz o consumo de combustíveis fósseis reduzindo a emissão de dióxido de carbono na camada de ozônio contribuindo para redução nas emissões de gases do efeito estufa.

REPLICABILIDADE: Total - Licença MIT

ABRANGÊNCIA TERRITORIAL: Global

COMPLEXIDADE: Média

INOVAÇÃO: Na forma como foi feita sim, no conceito não. Nenhum dos trabalhos anteriores entregou um pipeline aberto, reprodutível, documentado no GitHub, que qualquer pessoa pode clonar e rodar sobre seus próprios dados CAN. Molari usou dashcams + datalogger proprietário. Perozzi usou 61 tratores de uma única marca com dados fechados. Ninguém publicou o código. A contribuição metodológica não está no algoritmo de classificação, que é determinístico e deliberadamente simples, mas na arquitetura de dados que o torna escalável e replicável para qualquer frota equipada com ISOBUS ou J1939 — algo que até então não existia como recurso público.

SETOR DA SOCIEDADE BENEFICIADO PELO IMPACTO: Economicamente o setor rural e ecologicamente toda a sociedade civil.

DECLARAÇÃO DE VÍNCULO COM PDI DA INSTITUIÇÃO: Vínculo como aluno do Programa de Mestrado Profissional em Produção Vegetal do IFTM.

ESTÁGIO DA TECNOLOGIA: Inicial – testes de prova de conceito.

HÁ TRANSFERÊNCIA DE TECNOLOGIA/CONHECIMENTO? Sim

URL: <https://github.com/DTech1234/ALC-idletime>



REPÚBLICA FEDERATIVA DO BRASIL
MINISTÉRIO DO DESENVOLVIMENTO, INDÚSTRIA, COMÉRCIO E SERVIÇOS
INSTITUTO NACIONAL DA PROPRIEDADE INDUSTRIAL
DIRETORIA DE PATENTES, PROGRAMAS DE COMPUTADOR E TOPOGRAFIAS DE CIRCUITOS

Certificado de Registro de Programa de Computador

Processo Nº: **BR512026000883-2**

O Instituto Nacional da Propriedade Industrial expede o presente certificado de registro de programa de computador, válido por 50 anos a partir de 1º de janeiro subsequente à data de 09/02/2026, em conformidade com o §2º, art. 2º da Lei 9.609, de 19 de Fevereiro de 1998.

Título: Determinador de ociosidade de máquinas agrícolas

Data de publicação: 09/02/2026

Data de criação: 01/12/2025

Titular(es): DANIEL ABREU

Autor(es): DANIEL ABREU

Linguagem: PYTHON

Campo de aplicação: TC-02

Tipo de programa: AP-04

Algoritmo hash: SHA-512

Resumo digital hash:

75BF26E106D03C7DC78C4FDDC7511EF812B23B63E57E39C20F8CCDF4E5E84831183B13ACDE3FEC8032547052
B2E04728C1711A5729541947756D285F5FB6B02F

Expedido em: 18/02/2026

Aprovado por:

ERICA GUIMARAES CORREA

Chefe da Divisão de Programas de Computador e Topografias de Circuitos Integrados